崔翟斌

软硬件全栈与智能系统研发

工业预训练·PCB / FPGA / 固件·测控软件·精密实验

清华大学交叉信息研究院博士研究生 北京
cdb22@mails.tsinghua.edu.cn 15699919520（微信同号）
GitHub Google Scholar ORCID
https://zhaibin-cui.github.io/



核心能力

清华 IIIS 博士研究生，中科大物理学学士、AI+X 项目背景。具备 **MiniMax 工业预训练、独立训练框架和视觉算法研发经验**，同时**独立贯通 PCB、嵌入式/FPGA 固件、驱动协议与 API/UI**，统一数十台真实仪器。参与 Bell Ctrl 的 RISC-V 可编程测控与实时前馈，完成光学、真空、光电/射频及量子网络联调。擅长从原理分析进入工程实现，以测量、标定和系统验证定位问题，具备扎实 **STEM 基础与快速跨领域全栈开发能力**，累计 **10 篇论文成果**。

教育经历

清华大学·交叉信息研究院（IIIS） 2022.09 – 至今
博士研究生 | 基础模型训练与机制、视觉智能、量子信息与复杂物理系统

中国科学技术大学·物理学院 2018.09 – 2022.06
物理学学士 | AI+X 项目；校优秀毕业生
课程： 深度学习、多模态机器学习、深度强化学习、从头训练大语言模型；概率统计、数值计算；量子力学、电动力学、统计力学、量子场论。

工业预训练算法经验

MiniMax | 预训练算法工程师（实习） 在研
大规模 GPU 集群训练与预训练研究 | Scaling ·Evaluation ·Data Engineering

- **大规模预训练与 Scaling Ladder：** 参与**大规模 GPU 集群预训练**，覆盖 **1B / 3B / 10B 三级模型**；开展数据配方与训练配置的对照实验，分析收敛特性和下游能力，评估实验结论的跨尺度一致性。
- **Scaling Law：** 围绕参数规模、训练数据量与计算预算开展标度规律研究，分析训练损失及下游能力的尺度依赖；比较不同数据配方的 Scaling 趋势，为计算预算配置与训练方案选择提供实验依据。
- **Benchmark：** 参与预训练 Benchmark 与评测 Pipeline 建设，采用基于 **BPB（Bits-per-Byte）**的评估方法，结合知识、推理任务指标，开展 **Checkpoint 评估、分域能力分析与数据配方对比**。
- **Document Packing 与数据配方：** 针对文档边界、序列长度分布与 Padding 策略开展对照实验，评估**有效 Token 利用率、训练吞吐与验证损失**；结合分类分桶、质量分层、Data Mixture 与数据增强，研究样本构建和数据分布对预训练效果的影响。参与 Tokenization、数据分片与 DataLoader 等数据 Pipeline 开发和联调。

自主训练框架、数据与模型研究

MiniTrainSys：从零搭建预训练与受控研究平台 独立项目
架构设计与独立研发 | Sparse MoE ·DDP/FSDP 代码与实验

- **自主训练框架与模型实现：** 从零独立实现数据预处理、Byte-BPE、Token Shard、无 Padding Packing、模型、训练循环、检查点及评测模块；构建 **2.93 亿总参数 / 1.24 亿激活参数 Sparse MoE**（12 层、8 专家 / Top-2），支持数据配方、模型结构与训练配置的受控实验。
- **分布式训练与执行后端：** 按模型定义、算子后端和分布式执行分层，支持 **PyTorch/Triton/CUDA、BF16、DDP/FSDP**，实现 DCP 检查点与断点恢复；通过统一模型和数据接口支持预训练、冻结骨干探针及机制评测。同显存预算吞吐达到基线的 **2.201 倍**，四卡 RTX 4090 FSDP 弱扩展 **3.69 倍、效率 92.24%**。
- **受控数据与机制实验：** 参照 Physics of Language Models 完成两组各约 **4B-token** 预训练，姓名输入下属性首 Token 准确率 **98.79% vs. 12.83%**；冻结骨干并以真实首 Token 干预重训探针，完整属性读出由 **45.28% 升至 96.38%**，进一步研究隐式推理、Regret 与 CFG（在研）。

视觉表征、蒸馏与推理验证

PaGE：位置感知视觉交互与凝视估计 投稿 ICLR 2027
核心算法与数据研发 | Cross-Attention ·2D RoPE 论文

- **视觉交互与空间建模：** 参与 DINOv3 场景–头部双分支模块研发，通过**双向 Cross-Attention** 融合全局/局部特征；将头部 Patch 映射回场景坐标，以**统一坐标 2D RoPE** 编码位置、尺度与相对关系，结合 Self-Attention / FFN 预测凝视热图及画面内外状态。
- **数据、蒸馏与推理：** 构建 **60.8 万图像、117 万头部区域**蒸馏集，以 L1 + Cosine Token 对齐训练 **59M–0.2B** 学生模型；ViT-B 在 9 项指标中 **7 项超过论文人类基线**，GazeFollow AUC 0.966；ViT-S 在 RTX 4090 / i9-14900K 约 **16 / 190 ms/帧**（BF16）。

从板卡、固件到软件的全栈测控

- **独立软硬件架构：**从 PCB 与嵌入式/FPGA 固件向上实现设备驱动、通信协议、API/UI；按**硬件执行、设备通信、实验流程**划分接口，使数十台激光、射频、探测及时序设备共享控制入口，支持跨设备流程复用。
- **实验软件与自动标定：**实现谱线扫描、量子态相位标定、参数下发与数据采集；处理异步事件、设备依赖及异常返回，将**状态检查、参数边界、硬件互锁和日志**纳入运行流程，支持重复实验与故障定位。
- **Bell Ctrl 可编程执行：**参与核心系统研发，在 FPGA 内嵌 RISC-V 上实现支持**分支、循环、算术/逻辑运算及设备路由**的微指令测控，将高层实验流程编译为板上程序，支持随机光子探测后的条件执行。
- **实时事件链与性能验证：**联调**四通道 TDC、事件匹配、相位计算和 DDS**，系统实现 **11.5 ps RMS 时间分辨率与微秒级前馈**；沿事件输入、板上计算和输出补偿验证硬件接口、固件与上位机的协同执行。稿件
- **真实仪器 Agent 原型：**将设备能力封装为含类型、参数范围、前置状态和异常返回的工具，原型已接入装置，执行部分日常校准、参数维护、数据拟合和结果判断；复杂实验规划仍在验证。
- **设备服务与命令路由：**将相机、AWG、DDS、时序器、电压控制及 Notebook 接入同一命令总线，记录来源、目标、操作、结果和状态；贯通**实验脚本–设备服务–硬件执行–数据返回**，保留跨平台接口和诊断路径。
- **脉冲、成像与反馈工具：**开发 AWG 序列、RF/DDS 参数、阱电极电压、EMCCD 和光子计数控制界面；支持**离子图像 ROI、强度剖面、频率/脉冲扫描与拟合**，将可编程操作和实测信号放在同一工作流中核验。

光学、真空与量子实验验证

- **光学与真空平台：从零设计、搭建并调通两套离子阱平台**，贯通 Zemax 显微物镜/像差设计、UHV 真空、激光稳频、成像和射频驱动；结合**衍射传播与高斯模式匹配**，将原子单光子耦合至单模光纤，完成从物理方案到装置联调与实验验证。
- **跨域调试与物理验证：**维护激光纵模与 PDH 自动重新锁定，结合光子计数、谱线、图像和量子态测量，定位漂移、噪声、串扰和标定耦合；将控制流程接入离子装载、冷却、操控与探测，验证整机性能。
- **STEM 与量子研究：**掌握**量子计算/算法、量子存储、理论物理与数值计算**，合作开展可编程光量子存储和 DFS 编码存储；主导 12 km 离子–光子及 1.2 km 离子–离子纠缠，后者以 $95.9 \pm 1.5\%$ **刷新当时长距离物质节点预报纠缠保真度世界纪录**，相关工作获Phys.org 报道。

Agent 研究工具

- **模型接入与协同执行：**基于既有基线扩展 **Continuum Agent Harness**，统一多 Provider / API / Proxy 接入，实现**会话分支、Session Handoff 与上下文接续**；通过 A2A、可配置 MCP 与 Skills 组合组织任务委派、工具调用和结果交接，支持十余个主 Agent、各约 10 个子 Agent 的分层协作。
- **跨端状态管理：**实现桌面与移动端的**会话、工作区及草稿同步**，支持语音输入、项目/分支切换、代码变更审阅和远程训练监控，已用于日常模型研究与开发。

代表论文与学术成果

论文成果共 10 篇（7 篇已发表、3 篇稿件），代表成果如下。

[1] Z. Qin, Z. Shen, R. Yan, **Z. Cui et al.**, "A **Real-Time Feed-Forward System** for Heralded Quantum Entanglement," submitted to IEEE Transactions on Nuclear Science.

[2] **Z.-B. Cui et al.**, "**Metropolitan-scale Ion-Photon Entanglement** via a Quantum Network Node with Hybrid Multiplexing Enhancements," Nature Communications **17**, 697 (2026).

[3] **Z.-B. Cui et al.**, "**Temporally Multimode Ion-Ion Entanglement** over 1.2 Kilometer Fibers," Physical Review Letters **137**, 020803 (2026).

[4] Z. Ye*, C. Zhang*, **Z. Cui et al.**, "PAGE: Towards **Practical Human-level Gaze Target Estimation**," submitted to ICLR 2027; arXiv:2607.04860. 核心算法与数据贡献

其余成果：PRX、PRL（2 篇）、Science Advances、PRA；Nature Photonics 在审。完整列表

奖项与荣誉

清华之友–华为学者一等奖、三等奖；清华之友–长寿英才奖学金；清华大学校级实验室贡献奖二等奖、院级一等奖；中科大优秀毕业生、严济慈英才奖学金、金奖奖学金、张宗植科技奖学金。

专业技能

- **电子与实时系统：**PCB、嵌入式、Verilog、FPGA/RISC-V、微指令控制、TDC/DDS、事件匹配、实时前馈、硬件接口及系统联调；光电/射频、激光与探测器控制。
- **软件与测量：**Python、C/C++、驱动、协议、API/UI、命令路由、状态管理、互锁及自动标定；Zemax、精密成像、UHV、量子计算/算法、理论物理、数学建模和误差分析。
- **模型与工具：**PyTorch、Transformer / Sparse MoE、DDP/FSDP、BF16、DCP、CUDA/Triton 后端；Packing、Benchmark / BPB、视觉蒸馏；Linux、Git、Docker、MCP / Skills / A2A。

cdb22@mails.tsinghua.edu.cn 15699919520（微信同号） github.com/Zhaibin-Cui 北京