崔翟斌

AI Infra 与模型训练研究

大规模训练·数据系统·架构分析·软硬件全栈

清华大学交叉信息研究院博士研究生 北京
cdb22@mails.tsinghua.edu.cn 15699919520（微信同号）
GitHub Google Scholar ORCID
https://zhaibin-cui.github.io/



核心能力

清华 IIIS 博士研究生，中科大物理学学士、AI+X 项目背景。具备 **MiniMax 大规模 GPU 集群预训练经验**，研究数据配方、Packing、Scaling Ladder 与评测；**从零独立搭建 MiniTrainSys**，贯通模型、数据、DDP/FSDP、检查点和实验复现，实测四卡弱扩展 **3.69 倍**。理解 Attention / MoE 的显存、计算和通信取舍，并具备视觉模型压缩、Agent 工具链以及 **PCB–固件–驱动–API 全栈系统研发**经验，累计 **10 篇论文成果**。

教育经历

清华大学·交叉信息研究院（IIIS） 2022.09 – 至今
博士研究生 | 基础模型训练与机制、视觉智能、量子信息与复杂物理系统

中国科学技术大学·物理学院 2018.09 – 2022.06
物理学学士 | AI+X 项目；校优秀毕业生
课程： 深度学习、多模态机器学习、深度强化学习、从头训练大语言模型；概率统计、数值计算；量子力学、电动力学、统计力学、量子场论。

工业预训练算法经验

MiniMax | 预训练算法工程师（实习） 在研
大规模 GPU 集群训练与预训练研究 | Scaling ·Evaluation ·Data Engineering

- **大规模预训练与 Scaling Ladder：** 参与**大规模 GPU 集群预训练**，覆盖 **1B / 3B / 10B 三级模型**；开展数据配方与训练配置的对照实验，分析收敛特性和下游能力，评估实验结论的跨尺度一致性。
- **Scaling Law：** 围绕参数规模、训练数据量与计算预算开展标度规律研究，分析训练损失及下游能力的尺度依赖；比较不同数据配方的 Scaling 趋势，为计算预算配置与训练方案选择提供实验依据。
- **Benchmark：** 参与预训练 Benchmark 与评测 Pipeline 建设，采用基于 **BPB（Bits-per-Byte）**的评估方法，结合知识、推理任务指标，开展 **Checkpoint 评估、分域能力分析与数据配方对比**。
- **Document Packing 与数据配方：** 针对文档边界、序列长度分布与 Padding 策略开展对照实验，评估**有效 Token 利用率、训练吞吐与验证损失**；结合分类分桶、质量分层、Data Mixture 与数据增强，研究样本构建和数据分布对预训练效果的影响。
- **数据 Pipeline：** 参与预训练数据 Pipeline 的开发与联调，覆盖语料预处理、**Tokenization、数据分片、Document Packing 与 DataLoader**；通过预训练对照与 Benchmark 评测验证数据策略，支持数据配方迭代。

自主训练框架、数据与模型研究

MiniTrainSys：从零搭建预训练与受控研究平台 独立项目
架构设计与独立研发 | Sparse MoE ·DDP/FSDP 代码与实验

- **自主训练框架与模型实现：** 从零独立实现数据预处理、Byte-BPE、Token Shard、无 Padding Packing、模型、训练循环、检查点及评测模块；构建 **2.93 亿总参数 / 1.24 亿激活参数 Sparse MoE**（12 层、8 专家 / Top-2），支持数据配方、模型结构与训练配置的受控实验。
- **分布式训练与执行后端：** 按模型定义、算子后端和分布式执行分层，支持 **PyTorch/Triton/CUDA、BF16、DDP/FSDP**，实现 DCP 检查点与断点恢复；通过统一模型和数据接口支持预训练、冻结骨干探针及机制评测。
- **训练性能与扩展性：** 同显存预算下**训练吞吐达到基线的 2.201 倍**；四卡 RTX 4090 的 FSDP 弱扩展为 **3.69 倍、效率 92.24%**，通过显存占用、端到端吞吐和扩展效率评估执行后端与分布式训练方案。
- **数据与训练状态一致性：** 以 Manifest 记录 Tokenizer 指纹、Shard 哈希及预处理配置，配合 mmap 与受限映射缓存；按 Rank 分配确定性数据序列，通过 **DCP 恢复模型/Adam 状态**并独立加载合并模型评测，区分语言建模损失与路由正则。
- **数据与知识学习：** 参考 Allen-Zhu 的 **Physics of Language Models**，完成两组各约 **4B-token** 的 bioS 受控预训练；仅改变事实改写与排列，姓名输入下属性首 Token 准确率为 **98.79% vs. 12.83%**，改写重排组完整属性准确率为 33.15%，分别评估知识提取入口与完整生成。
- **机制归因与因果干预：** 冻结骨干、加入真实首 Token 干预并**重新训练读出探针**，改写重排组完整属性读出由 **45.28%** 升至 **96.38%**；结合隐藏状态与专家路由分析，研究知识可读出而生成受阻的机制。
- **机制研究（在研）：** 通过隐藏状态、专家路由与数据对照，研究**隐式推理、Regret 错误识别/回退及 CFG 层级结构学习**，考察推理深度、错误–纠正数据与训练未见结构的泛化。

模型架构与训练系统分析

- **Attention 与推理内存：**从 Prefill/Decode 的张量形状、序列长度和批量分析计算与带宽代价；理解 GQA/MLA 的 KV Cache 压缩、缓存布局及吞吐–延迟取舍。
- **MoE 与分布式执行：**理解 Router Top-k、Token Dispatch/Combine 与专家 GEMM 的数据流，关注负载不均、All-to-All、EP/TP 切分和通信–计算重叠；以可复现实验区分模型、数据加载与执行开销。

Agent 系统与研究工作站

Continuum：跨模型、多 Agent、跨端协同 持续开发

基于既有基线扩展，负责功能开发与系统集成 | Session Handoff ·MCP / Skills ·A2A

- **模型接入与协同执行：**基于既有基线扩展 **Continuum Agent Harness**，统一多 Provider / API / Proxy 接入，实现**会话分支、Session Handoff 与上下文接续**；通过 A2A、可配置 MCP 与 Skills 组合组织任务委派、工具调用和结果交接，支持十余个主 Agent、各约 10 个子 Agent 的分层协作。
- **研发工具与实验工作流：**集成 Linux Bash、Git、文件工作区、Docker、训练作业管理与 **W&B 实验追踪**；接入飞书文档/机器人和授权资料检索，将调研、代码修改、实验分析与文档交付串联为可复用工作流。
- **跨端状态管理：**实现桌面与移动端的**会话、工作区及草稿同步**，支持语音输入、项目/分支切换、代码变更审阅和远程训练监控，已用于日常模型研究与开发。

视觉表征、蒸馏与推理验证

PaGE：位置感知视觉交互与凝视估计 投稿 ICLR 2027

核心算法与数据研发 | Cross-Attention ·2D RoPE 论文

- **视觉交互与空间建模：**参与 DINOv3 场景–头部双分支模块研发，通过**双向 Cross-Attention** 融合全局/局部特征；将头部 Patch 映射回场景坐标，以**统一坐标 2D RoPE** 编码位置、尺度与相对关系，结合 Self-Attention / FFN 预测凝视热图及画面内外状态。
- **数据、蒸馏与推理：**构建 **60.8 万图像、117 万头部区域**蒸馏集，以 L1 + Cosine Token 对齐训练 **59M–0.2B** 学生模型；ViT-B 在 9 项指标中 **7 项超过论文人类基线**，GazeFollow AUC 0.966；ViT-S 在 RTX 4090 / i9-14900K 约 **16 / 190 ms/帧**（BF16）。

全栈实验系统与 STEM 研究基础

- **光学与真空平台：从零设计、搭建并调通两套离子阱平台**，贯通 Zemax 显微物镜/像差设计、UHV 真空、激光稳频、成像和射频驱动；结合**衍射传播与高斯模式匹配**，将原子单光子耦合至单模光纤，完成从物理方案到装置联调与实验验证。
- **软硬件全栈：**独立开发 **PCB、嵌入式/FPGA 固件、设备驱动、通信协议及 API/UI**，统一数十台激光、射频、探测与时序设备；实现谱线扫描、相位标定和数据采集，并将状态检查、参数边界、互锁和异常返回纳入执行流程。
- **实时测控：**参与 **Bell Ctrl** 核心系统研发，在 FPGA/RISC-V 上实现支持分支、循环和运算的可编程测控；集成 TDC、事件匹配、相位计算与 DDS，系统达到 **11.5 ps RMS 时间分辨率、微秒级前馈**。稿件
- **STEM 与量子研究：**掌握**量子计算/算法、量子存储、理论物理与数值计算**，合作开展可编程光量子存储和 DFS 编码存储；主导 12 km 离子–光子及 1.2 km 离子–离子纠缠，后者以 $95.9 \pm 1.5\%$ **刷新当时长距离物质节点预报纠缠保真度世界纪录**，相关工作获Phys.org 报道。

代表论文与学术成果

论文成果共 10 篇（7 篇已发表、3 篇稿件），代表成果如下。

[1] Z. Ye*, C. Zhang*, **Z. Cui et al.**, "PAGE: Towards **Practical Human-level Gaze Target Estimation**," submitted to ICLR 2027; arXiv:2607.04860. 核心算法与数据贡献

[2] **Z.-B. Cui et al.**, "**Metropolitan-scale Ion-Photon Entanglement** via a Quantum Network Node with Hybrid Multiplexing Enhancements," Nature Communications **17**, 697 (2026).

[3] **Z.-B. Cui et al.**, "**Temporally Multimode Ion-Ion Entanglement** over 1.2 Kilometer Fibers," Physical Review Letters **137**, 020803 (2026).

其余成果：PRX、PRL（2 篇）、Science Advances、PRA；Nature Photonics 在审、IEEE TNS 投稿。完整列表

奖项与荣誉

清华之友–华为学者一等奖、三等奖；清华之友–长寿英才奖学金；清华大学校级实验室贡献奖二等奖、院级一等奖；中科大优秀毕业生、严济慈英才奖学金、金奖奖学金、张宗植科技奖学金。

专业技能

- **模型与训练：**Python、C/C++、PyTorch、Transformer / Sparse MoE、DDP/FSDP、BF16、DCP、NCCL；CUDA/Triton 后端实践，了解 GQA/MLA、KV Cache、专家路由/通信及 VLM/VLA/WAM 基本架构。
- **数据与系统：**Scaling 实验、Benchmark / BPB、数据配方、Packing、视觉蒸馏；MCP、Skills、A2A、会话管理；Linux/Bash、Git、Docker、W&B、桌面与移动端工具集成。
- **物理与硬件：**量子计算与算法、量子存储、理论物理、数学建模；Zemax、精密光学、衍射/高斯光学、UHV、PCB、嵌入式、FPGA/RISC-V、光电/射频与实验自动化。

cdb22@mails.tsinghua.edu.cn 15699919520（微信同号） github.com/Zhaibin-Cui 北京